ISSN: 2339-2541
JURNAL GAUSSIAN, Volume X, Nomor X, Tahun XXXX, Halaman XX - XX
Online di: https://ejournal3.undip.ac.id/index.php/gaussian/

PENGELOMPOKAN KABUPATEN/KOTA DI INDONESIA BERDASARKAN INDIKATOR KEMISKINAN MENGGUNAKAN DENSITY-BASED CLUSTERING (DENCLUE)

Ageng Windarto Jati[1], Moch. Abdul Mukid[2*], Diah Safitri[3]
[1,2,3] Departemen Statistika, Fakultas Sains dan Matematika, Universitas Diponegoro
***e-mail** : m.abdul.mukid78@gmail.com

DOI: 10.14710/J.GAUSS.XX.X.XX-XX

Article Info:
Received:
Accepted:
Available Online:

Keywords:
Cluster Analysis; DENCLUE, DBCV; *Euclidean Distance*; *Density-Based Clustering*; *Poverty*

Abstract: Poverty remains one of the major economic issues faced by many countries and is commonly used as an indicator of a nation's development. One approach to analyzing the severity of poverty conditions across regions in Indonesia is clustering regencies and municipalities based on poverty indicators. This study applies the Density-Based Clustering (DENCLUE) algorithm to group regencies and municipalities in Indonesia according to poverty-related indicators. The data were obtained from the publication Data dan Informasi Kemiskinan Kabupaten/Kota Volume 17 Tahun 2025 issued by Statistics Indonesia (BPS), covering 514 regencies and municipalities throughout Indonesia. The DENCLUE method was implemented through data standardization, identification of density attractors, merging of density attractors based on a specified radius, and cluster formation using a density threshold. The quality of the clustering results was evaluated using Density-Based Clustering Validation (DBCV). The results indicate that the optimal parameters were a sigma value of 1.3, an attractor merging radius of 0.07, and a density threshold of 1, yielding a DBCV score of 0.8152, which indicates a high-quality clustering structure. Based on these parameters, six clusters were formed with 223, 285, 1, 3, 1, and 1 regencies/municipalities, respectively.

1. PENDAHULUAN

Kemiskinan merupakan salah satu permasalahan utama yang masih dihadapi oleh berbagai negara, terutama negara berkembang seperti Indonesia. Selain mencerminkan rendahnya tingkat kesejahteraan masyarakat, kemiskinan juga menjadi indikator penting dalam menilai keberhasilan pembangunan suatu negara. Pertumbuhan ekonomi yang tinggi tidak selalu diikuti oleh penurunan tingkat kemiskinan secara signifikan karena kemiskinan dipengaruhi oleh berbagai aspek, seperti pendidikan, ketenagakerjaan, pola konsumsi, serta akses terhadap fasilitas dasar. Menurut konsep Badan Pusat Statistik (BPS), kemiskinan diukur berdasarkan kemampuan seseorang dalam memenuhi kebutuhan dasar makanan dan bukan makanan yang dinilai melalui garis kemiskinan. Oleh karena itu, kemiskinan merupakan permasalahan multidimensi yang memerlukan analisis secara komprehensif agar kebijakan penanggulangannya dapat disusun secara tepat sasaran.

Berdasarkan publikasi Profil Kemiskinan di Indonesia bulan Maret 2025, persentase penduduk miskin Indonesia tercatat sebesar 8,47% atau sekitar 25,14 juta jiwa. Meskipun angka tersebut menunjukkan penurunan dibandingkan periode sebelumnya, kondisi kemiskinan antar kabupaten/kota di Indonesia masih menunjukkan perbedaan yang cukup besar. Perbedaan karakteristik tersebut menyebabkan kebijakan penanggulangan kemiskinan yang bersifat seragam menjadi kurang efektif. Oleh karena itu, diperlukan suatu pendekatan yang mampu mengelompokkan kabupaten/kota berdasarkan kemiripan indikator

kemiskinan sehingga dapat memberikan informasi yang mendukung penyusunan kebijakan pembangunan dan penanggulangan kemiskinan yang lebih terarah.

Salah satu teknik yang dapat digunakan untuk mengidentifikasi kemiripan karakteristik antar wilayah adalah analisis klaster (*clustering*). *Clustering* bertujuan mengelompokkan objek ke dalam beberapa kelompok sehingga objek dalam satu kelompok memiliki tingkat kemiripan yang tinggi, sedangkan objek antar kelompok memiliki karakteristik yang berbeda. Berbagai metode *clustering* telah banyak digunakan, namun metode yang hanya mengandalkan ukuran jarak umumnya kurang mampu menangani data dengan bentuk *cluster* yang tidak beraturan serta keberadaan *noise* atau *outlier*. Oleh karena itu, diperlukan metode *clustering* yang mempertimbangkan struktur kepadatan data sehingga mampu menghasilkan pengelompokan yang lebih representatif.

Salah satu metode *density-based clustering* yang dapat digunakan adalah DENCLUE. DENCLUE merupakan metode *clustering* berbasis kepadatan yang memanfaatkan *Kernel Density Estimation* (KDE) untuk membentuk fungsi kepadatan data (Davis *et al.,* 2011), kemudian menentukan pusat kepadatan *(density attractor*) melalui proses *hill climbing*. Objek yang memiliki *density attractor* yang sama atau saling terhubung akan dikelompokkan ke dalam *cluster* yang sama. Pendekatan ini memiliki keunggulan dalam mengidentifikasi *cluster* dengan bentuk arbitrer, lebih *robust* terhadap *noise*, serta mampu diterapkan pada data berdimensi tinggi. Pada penelitian ini digunakan fungsi kernel Gaussian sebagai fungsi pengaruh dalam pembentukan fungsi kepadatan.

Evaluasi kualitas hasil clustering juga menjadi tahapan yang penting dalam penelitian ini. Mengingat DENCLUE merupakan metode *clustering* berbasis kepadatan, maka digunakan *Density-Based Clustering Validation* (DBCV) sebagai indeks validasi internal. Berbeda dengan indeks validasi yang hanya mengandalkan jarak antar objek, DBCV mengevaluasi kualitas *cluster* berdasarkan struktur kepadatan melalui konsep *Density Sparseness of Cluster* dan *Density Separation of Clusters*. Dengan demikian, DBCV dinilai lebih sesuai untuk mengevaluasi hasil *clustering* yang dihasilkan oleh algoritma berbasis kepadatan.

Berdasarkan uraian tersebut, penelitian ini bertujuan menerapkan algoritma DENCLUE untuk mengelompokkan 514 kabupaten/kota di Indonesia berdasarkan indikator kemiskinan yang bersumber dari publikasi Data dan Informasi Kemiskinan Kabupaten/Kota Volume 17 Tahun 2025 yang diterbitkan oleh Badan Pusat Statistik. Selain itu, penelitian ini bertujuan menentukan parameter terbaik menggunakan indeks validasi DBCV serta menyusun profil masing-masing *cluster* berdasarkan karakteristik indikator kemiskinan yang dimiliki sehingga hasil pengelompokan dapat menjadi informasi pendukung dalam penyusunan kebijakan penanggulangan kemiskinan yang lebih tepat sasaran.

2. TINJAUAN PUSTAKA

Variabel penelitian distandarisasi apabila variabel yang diteliti terdapat perbedaan satuan. Perbedaan tersebut dapat mengakibatkan perhitungan analisis cluster menjadi tidak valid. Maka dari itu proses dari standarisasi data bertujuan untuk menyamakan satuan dari seluruh variabel penelitian. Hasil akhir dari standarisasi data tidak mengubah pola distribusi data. Standarisasi data yang paling umum digunakan yaitu konversi setiap nilai data pada variabel ke dalam nilai *Z-score* dengan cara nilai objek pada variabel dikurangi nilai rata-rata variabel dibagi dengan nilai standar deviasi variabel. Rumus standarisasi data sebagai berikut (Walpole & Myers, 1995):

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j} \quad (1)$$

Jarak euclidean merupakan suatu metode perhitungan jarak yang dapat digunakan dalam menghitung jarak dari dua buah titik dalam euclidean *space* (Anton & Kaul, 2019). Metode dalam penghitungan jarak yang paling populer digunakan adalah jarak euclidean. Pada dasarnya, jarak ini digunakan dengan cara memasukkan sebuah objek ke dalam sebuah *cluster* lalu mengukur jarak objek tersebut dengan pusat *cluster*. Objek tersebut akan dimasukkan ke dalam *cluster* tersebut apabila objek berada dalam jarak yang termasuk ke dalam batas tertentu. Jarak euclidean mempunyai rumus sebagai berikut:

$$d(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{\sum_{l=1}^{p} (x_{il} - x_{jl})^2} \quad (2)$$

DENCLUE merupakan suatu algoritma yang berdasarkan konektivitas dan *density functions* (Hinneburg & Keim, 1998). Dalam penentuan *cluster*, algoritma DENCLUE harus memenuhi *set of points* yang disebut *density attractors*. *Attractor* tersebut nantinya akan dianggap sebagai *local maximum* dari *density function*. DENCLUE didasarkan pada perhitungan *influence of points* data satu sama lain. Beberapa *influence functions* berdasarkan jarak antara dua titik **x** dan $\mathbf{x_i}$, seperti fungsi Gaussian pada Persamaan 3.

$$K_\sigma(\mathbf{x}, \mathbf{x}_i) = \exp\left(-\frac{d(\mathbf{x}, \mathbf{x_i})^2}{2\sigma^2}\right) \quad (3)$$

Total penjumlahan dari *influence functions* yang menentukan *density function* sebagai berikut.

$$f(\mathbf{x}) = \sum_{i=1}^{N} K_\sigma(\mathbf{x}, \mathbf{x}_i) \quad (4)$$

Karena fungsi densitas merupakan penjumlahan dari seluruh kernel, maka gradien total diperoleh dengan menjumlahkan turunan masing-masing komponen. Sehingga menghasilkan Persamaan 5 yang merupakan rumus dari gradien fungsi kepadatan.

$$\nabla f(\mathbf{x}) = \begin{pmatrix} \frac{\partial f(\mathbf{x})}{\partial x_1} \\ \frac{\partial f(\mathbf{x})}{\partial x_2} \\ \frac{\partial f(\mathbf{x})}{\partial x_3} \\ \vdots \\ \frac{\partial f(\mathbf{x})}{\partial x_p} \end{pmatrix} = \begin{pmatrix} \frac{\partial \sum_{i=1}^{N} K_\sigma(\mathbf{x}, \mathbf{x}_i)}{\partial x_1} \\ \frac{\partial \sum_{i=1}^{N} K_\sigma(\mathbf{x}, \mathbf{x}_i)}{\partial x_2} \\ \frac{\partial \sum_{i=1}^{N} K_\sigma(\mathbf{x}, \mathbf{x}_i)}{\partial x_3} \\ \vdots \\ \frac{\partial \sum_{i=1}^{N} K_\sigma(\mathbf{x}, \mathbf{x}_i)}{\partial x_p} \end{pmatrix} = \sum_{i=1}^{N} \frac{\mathbf{x}_i - \mathbf{x}}{\sigma^2} K_\sigma(\mathbf{x}, \mathbf{x}_i) \quad (5)$$

Selanjutnya dilakukan perhitungan titik *attractor*. Pada titik *attractor*, terdapat beberapa variabel yang ikut mempengaruhi seperti nilai gradien dan normalisasi gradien. Berikut pada Persamaan 6 merupakan rumus iterasi *hill climbing* untuk mencari nilai dari titik *attractor*.

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} + \delta \frac{\nabla f(\mathbf{x}^{(t)})}{\|\nabla f(\mathbf{x}^{(t)})\|} \quad (6)$$

Iterasi dihentikan ketika

$$d\left(\mathbf{x}^{(t+1)} - \mathbf{x}^{(t)}\right) < \varepsilon \quad (7)$$

Jika kondisi tersebut bernilai benar, maka algoritma dihentikan dan mendapatkan titik sebagai lokal maksimum atau titik *attractor*. Setelah titik *attractor* diperoleh menggunakan proses *hill climb*, langkah selanjutnya dalam algoritma DENCLUE adalah mengelompokan *attractor-attractor* tersebut untuk membentuk *cluster*. Proses ini dilakukan menggunakan parameter *neighborhood radius* (r_a) yaitu jarak maksimum antar titik *attractor* yang masih dianggap berasal dari *cluster* yang sama. Pemilihan nilai optimal untuk r_a dilakukan dengan *trial and error*, karena bersifat sensitif dan tidak ada ketentuan yang mengikat (Ajmal *et al.*, 2024). Secara matematis, dua titik *attractor* akan digabungkan ke dalam satu *attractor* apabila memenuhi kondisi:

$$d\left(\mathbf{x}_{\boldsymbol{i}}^{*}, \mathbf{x}_{\boldsymbol{j}}^{*}\right) \leq r_a \quad (8)$$

Moulavi memperkenalkan *Density-Based Clustering Validation* (DBCV). DBCV mengevaluasi kualitas *cluster* berdasarkan konektivitas densitas antar objek, sehingga mampu menilai validitas *cluster* yang memiliki bentuk acak, kepadatan yang bervariasi, serta mampu menangani keberadaan data *noise* (Moulavi *et al.,* 2014). Perhitungan indeks DBCV didasarkan pada visualisasi topografi densitas yang dihitung melalui fungsi kepadatan kernel. APCD adalah ukuran yang menggambarkan tingkat kepadatan di sekitar suatu objek dengan mempertimbangkan seluruh titik lain yang berada dalam *cluster* yang sama. Terdapat dua komponen utama yang digunakan untuk mengevaluasi kualitas *cluster*, yaitu *Density Sparseness of a Cluster* (DSC) dan *Density Separation of Clusters* (DSP). DSC bertujuan mengukur tingkat kerenggangan maksimum di dalam suatu *cluster*. Secara konseptual, DSC merepresentasikan area dengan kepadatan paling rendah (lembah terendah) di dalam klaster tersebut. Sementara DSP mengukur tingkat pemisahan densitas antar dua *cluster* yang berbeda. DSP merepresentasikan titik dengan kepadatan tertinggi (puncak tertinggi) yang memisahkan batas luar antara dua *cluster*. Tahapan dari DBCV dapat dilakukan dengan sebagai berikut.

1. Hitung semua nilai *core distance* pada setiap titik menggunakan rumus

$$APCD\left(\mathbf{x}_{\mathrm{i}}, \mathbf{x}_{\mathrm{j}}\right) = \left(\frac{1}{p-1}\sum_{i \neq j}\frac{1}{d(\mathbf{x}_{\mathrm{i}}, \mathbf{x}_{\mathrm{j}})^n}\right)^{-\frac{1}{n}} \quad (9)$$

2. Ambil nilai maksimal antara nilai *core distance* $\mathbf{x}_{\mathrm{i}}, \mathbf{x}_{\mathrm{j}}$, dan jarak euclidean antar objek sebagai *mutual reachability distance* (MRD) dengan rumus

$$MRD\left(\mathbf{x}_{\mathrm{i}}, \mathbf{x}_{\mathrm{j}}\right) = max\left\{APCD(\mathbf{x}_{\mathrm{i}}), APCD\left(\mathbf{x}_{\mathrm{j}}\right), d\left(\mathbf{x}_{\mathrm{i}}, \mathbf{x}_{\mathrm{j}}\right)\right\} \quad (10)$$

3. Buat matriks *mutual reachability distance* (MRD) menggunakan nilai maksimal yang di dapat sebagai bobot. Gabungkan semua nilai bobot terkecil untuk merangkai titik data pertama sampai titik data terakhir *cluster* maka akan didapatkan nilai *minimum spanning tree* (MST).

4. Ambil nilai terbesar antara tiap bobot yang merangkai titik data pertama sampai terakhir *cluster* sebagai *Density Sparseness of a Cluster* (DSC) atau bobot terrenggang *cluster* tersebut.
5. Ambil nilai *mutual reachability distance* (MRD) terkecil yang memisahkan 2 titik data menjadi *cluster* berbeda sebagai *Density Separation of Clusters* (DSP) atau jarak terpendek antar *cluster*.
6. Hitung indeks validitas untuk sebuah *cluster* menggunakan rumus indeks validitas *cluster*.

$$V_C(C_i) = \frac{min_{j \neq i}\left(DSP(C_i, C_j)\right) - DSC(C_i)}{max\left(min_{j \neq i}\left(DSP(C_i, C_j)\right), DSC(C_i)\right)} \quad (11)$$

7. Setelah semua *cluster* individual V_C selesai dihitung, kemudian satukan nilai tersebut menjadi satu skor akhir (skor global DBCV).

$$\text{DBCV} = \sum_{i=1}^{k} \frac{|C_i|}{|N|} \cdot V_C(C_i) \quad (12)$$

Dari nilai DBCV didapatkan rentang nilai antara -1 hingga +1. Jika nilai mendekati +1 maka menunjukan hasil klasterisasi yang sangat optimal. Sebaliknya jika mendekati 0 atau negatif menunjukan kualitas klaster buruk.

3. METODE PENELITIAN

Penelitian ini merupakan penelitian kuantitatif menggunakan data yang terdiri dari setiap kota/kabupaten di Indonesia yang diperoleh dari website Badan Pusat Statistik Indonesia: https://www.bps.go.id/id. Data yang digunakan adalah data sekunder publikasi Data dan Informasi Kemiskinan Kabupaten/Kota Indonesia pada tahun 2025. Terdapat 8 variabel yang digunakan pada penelitian ini yang disajikan dalam Tabel 1 beserta struktur data disajikan dalam Tabel 2.

Tabel 1. Variabel Penelitian

Variabel	Keterangan	Satuan
X_1	Masyarakat Miskin	Persen
X_2	P2 (Indeks Keparahan Kemiskinan)	Rasio
X_3	Penduduk lulus SD/SMP	Persen
X_4	Penduduk Tidak Bekerja	Persen
X_5	Penduduk Bekerja di Sektor Informal	Persen
X_6	Pengeluaran Untuk Makan	Persen
X_7	Penduduk Mempunyai Akses Air	Persen
X_8	Penduduk Mempunyai Sanitasi yang Layak	Persen

Tabel 2. Struktur Data Objek dan Variabel

Kabupaten/Kota di Indonesia (i)	X_1	X_2	X_3	...	X_8
1	$X_{1,1}$	$X_{1,2}$	$X_{1,3}$	...	$X_{1,8}$
2	$X_{2,1}$	$X_{2,2}$	$X_{2,3}$	...	$X_{2,8}$
3	$X_{3,1}$	$X_{3,2}$	$X_{3,3}$	...	$X_{3,8}$
...	...	...	...	...	...
514	$X_{154,1}$	$X_{154,2}$	$X_{154,3}$	...	$X_{154,8}$

Software yang digunakan dalam penelitian ini adalah *software RStudio* dan Microsoft Excel 2019. Langkah-langkah yang dilakukan dalam analisis data adalah sebagai berikut.

1. Pengumpulan data penelitian
2. Seleksi dan penentuan variabel penelitian
3. Standarisasi data
4. Penentuan parameter DENCLUE
    1. *bandwidth* atau lebar kernel (σ)
    2. nilai batas konvergensi (ε)
    3. radius *neighborhood* (r_a)
    4. ambang batas kepadatan (ξ)
5. Menghitung jarak Euclidean
6. Hitung nilai *influence point* setiap objek
7. Perhitungan nilai total fungsi kepadatan menggunakan kernel Gaussian
8. Mencari titik *attractor* dengan *hill climbing*
9. Menentukan banyak titik *attractor*
10. Pembentukan klaster berdasarkan *density attractor* dan nilai kepadatan
11. Evaluasi kualitas klister
12. Visualisasi hasil Clustering

4. HASIL DAN PEMBAHASAN

Data pada penelitian ini merupakan data indikator kemiskinan dari setiap kabupaten/kota di Indonesia yang berfokus pada penduduk miskin pada tahun 2025, yaitu persentase masyarakat miskin (X_1), indeks keparahan kemiskinan (X_2), persentase penduduk lulus SD/SMP (X_3), persentase penduduk tidak bekerja (X_4), persentase penduduk bekerja di sektor informal (X_5), persentase pengeluaran untuk makan (X_6), persentase penduduk mempunyai akses air (X_7), dan persentase penduduk mempunyai sanitasi layak (X_8). Data tersebut merupakan data sekunder yang bersumber dari website Badan Pusat Statistik (BPS).

Standarisasi dilakukan untuk menyamakan satuan data pada seluruh variabel penelitian. Hal ini dilakukan karena terdapat satuan yang berbeda pada data di dalam variabel penelitian, dengan menghitung manual pada Microsoft Excel disajikan pada Tabel 4 berikut ini:

Tabel 3. Standarisasi Objek Penelitian

Objek ke-	X_1	X_2	X_3	...	X_8
1	0,71493	0,12897	1,26358	...	-1,4124
2	0,93888	1,05376	0,31852	...	-0,2693
3	-0,0985	0,13506	0,12805	...	0,39325
4	-0,1144	-0,4727	-0,5522	...	-0,53
5	0,09653	-0,495	1,02051	...	0,23203
⋮	⋮	⋮	⋮	...	⋮
514	2,21035	-0,2145	-3,3366	...	-4,123

Terdapat 4 parameter yang akan digunakan yaitu, σ atau sigma berfungsi untuk menentukan lebar kernel, ξ atau *threshold* berfungsi menjadi ambang batas kerapatan dalam menentukan klaster, *neighborhood radius* (r_a) yaitu jarak maksimum antar titik *attractor* yang masih dianggap berasal dari *attractor* yang sama, dan ε atau epsilon untuk menentukan kapan iterasi gradien dapat dihentikan. Parameter yang digunakan pada algoritma ditentukan oleh peneliti sendiri. Peneliti menetapkan nilai lebar kernel sejauh 1,3 untuk data penelitian, nilai threshold 1, *neighborhood radius* (r_a) sebesar 0,07, dan epsilon sebesar 0,0001.

Matriks jarak Euclidean pada Tabel 4 merupakan hasil perhitungan jarak antar 514 kabupaten/kota yang menjadi objek penelitian. Karena ukuran matriks yang dihasilkan adalah 514 × 514, hanya sebagian matriks yang ditampilkan.

Tabel 4. Matriks Jarak Euclidean Objek Penelitian

Objek ke-	X_1	X_2	X_3	...	X_{514}
1	0,000	2,050	2,806	...	7,877
2	2,050	0,000	1,998	...	7,597
3	2,806	1,998	0,000	...	6,649
⋮	⋮	⋮	⋮	...	⋮
514	7,877	7,597	6,649	...	0,000

DENCLUE didasarkan pada perhitungan *influence of points* data satu sama lain. Fungsi kernel yang di gunakan adalah Gaussian seperti pada Persamaan (3). Tabel 5 menunjukkan matriks nilai kernel dari seluruh objek penelitian dengan parameter *bandwidth* (σ) yang telah ditentukan. Karena ukuran matriks yang dihasilkan sangat besar, hanya sebagian matriks yang ditampilkan.

Tabel 5. Matriks Nilai kernel Gaussian Objek Penelitian

Objek ke-	1	2	3	...	514
1	1	0,288	0,097	...	0,000
2	0,288	1	0,030	...	0,000
3	0,097	0,030	1	...	0,000
⋮	⋮	⋮	⋮	...	⋮
514	0,000	0,000	0,000	...	1

Total penjumlahan dari *influence functions* yang menentukan *density function* pada titik objek diperlihatkan pada Persamaan (4). Dalam DENCLUE, objek pengamatan direpresentasikan dengan struktur *hyper-rectangle*. Struktur ini dibangun dengan fungsi kepadatan kontinu menggunakan kernel, dimana pada $f(\mathbf{x})$ akan menghasilkan nilai sebanyak objek pengamatan yang ada. Menentukan titik *attractor* menggunakan metode *hill climbing*. Jika 2 objek pengamatan menuju *attractor* yang sama maka dianggap 1 klaster. Metode ini akan bergerak ke arah sekitar densitas objek untuk melihat daerah densitas yang lebih tinggi dan jika tidak ada densitas yg lebih tinggi maka itu merupakan titik *density attractor*. Metode ini menggunakan gradien dari fungsi densitas sesuai pada Persamaan (5).

Setelah menetapkan nilai δ atau delta sebesar 0,1, maksimum iterasi sebanyak 100, dan epsilon sebesar 0,0001 didapatkan hasil *hill climb* sebanyak 514 titik. Sesuai dengan nilai radius *neighborhood* (r_a) yang sudah ditetapkan maka penggabungan titik *attractor* dapat dilakukan dan menghasilkan 6 titik. Pada objek penelitian semua titik tergolong dalam klaster sehingga *output* yang dihasilkan berupa 6 klaster dengan rincian, klaster 1 dengan 223 objek, klaster 2 dengan 285 objek, klaster 3 dengan 1 objek, klaster 4 dengan 3 objek, klaster 5 dengan 1 objek, dan klaster 6 dengan 1 objek. Hal tersebut karena adanya kontribusi kepadatan dari banyak titik data lain di sekitar objek. Akumulasi kontribusi kernel Gaussian tersebut menyebabkan nilai densitas *attractor* melebihi dari *threshold*, sehingga dinyatakan masuk menjadi anggota klaster.

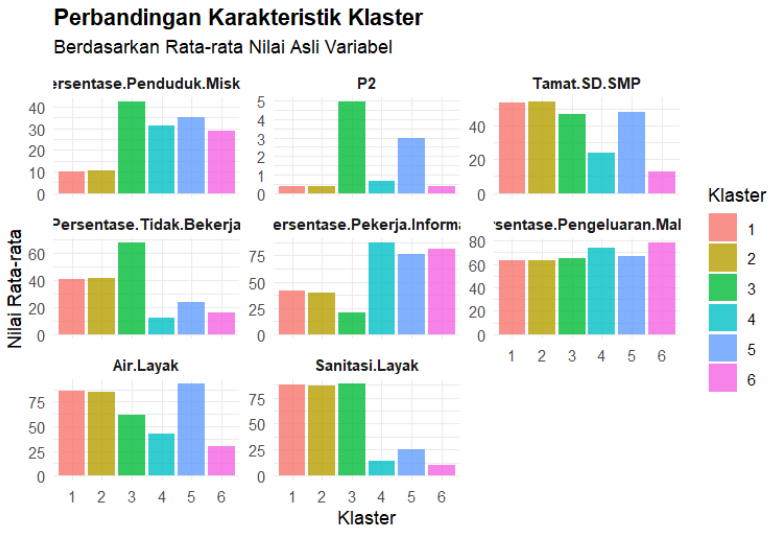
Berdasarkan hasil pengelompokan data penelitian menggunakan metode *density-base clustering* (DENCLUE) diperoleh nilai *Density-Based Clustering Validation* (DBCV) sebesar 0,8152. Dengan demikian, metode DENCLUE terbukti mampu menangkap struktur

kepadatan data secara efektif, terutama dalam mengidentifikasi klaster utama, meskipun evaluasi lanjutan tetap diperlukan untuk memperoleh hasil yang lebih optimal. Interpretasi dilakukan untuk mengetahui karakteristik dari klaster yang terbentuk. Klasterisasi digunakan untuk mengetahui kabupaten/kota di Indonesia yang memerlukan perhatian lebih dari pemerintah dalam usaha meningkatkan kualitas dan kesejahteraan dari suatu daerah. Dalam hal ini, penduduk miskin berdasarkan indikator kemiskinan yang dapat dilihat dari persentase masyarakat miskin, indeks keparahan kemiskinan, persentase penduduk lulus SD/SMP, persentase penduduk tidak bekerja, persentase penduduk bekerja di sektor informal, persentase pengeluaran untuk makan, persentase penduduk mempunyai akses air, dan persentase penduduk mempunyai sanitasi layak. Profilisasi klasifikasi dilakukan menggunakan hasil dari algoritma DENCLUE sebagai berikut:

Tabel 6. Hasil *Clustering* DENCLUE

Kategori	Jumlah anggota	Kabupaten/Kota
Klaster 1	223	Simueulue, Aceh Singkil, Aceh Selatan, Aceh Tenggara,..., Kota Jayapura, Asmat, Nabire, Jayawijaya, dan Lanny Jaya.
Klaster 2	285	Aceh Barat, Aceh Besar, Pidie, Aceh Utara, Aceh Barat Daya,..., Mimika, Dogiyai, Deiyai, Nduga, dan Yalimo
Klaster 3	1	Supiori
Klaster 4	3	Puncak, Yakuhimo, dan Pegunungan Bintang
Klaster 5	1	Puncak Jaya
Klaster 6	1	Tolikara

Berdasarkan hasil *clustering* pada Tabel 6 dapat dilihat daerah mana saja yang jumlah penduduk miskinnya perlu ditekan lebih signifikan. Mayoritas dari daerah tersebut terletak pada Indonesia bagian timur. Mengisyaratkan bahwa kesejahteraan belum merata terutama di bagian Indonesia yang cukup jauh dari pusat pemerintahan.



Gambar 1. Visualisasi Karakteristik tiap Variabel

Berdasarkan karakteristik tersebut, Klaster 1 merupakan kelompok wilayah dengan tingkat kesejahteraan yang relatif baik. Hal ini ditunjukkan oleh persentase penduduk miskin sebesar 10,117% dan nilai P2 sebesar 0,387 yang termasuk paling rendah dibandingkan klaster lainnya. Tingkat pendidikan penduduk relatif tinggi dengan persentase tamat SD/SMP sebesar 53,301%, sedangkan persentase penduduk yang tidak bekerja sebesar 41,167%. Selain itu, akses terhadap air minum layak dan sanitasi layak sangat baik, masing-masing sebesar 86,127% dan 87,455%. Karakteristik tersebut menunjukkan bahwa wilayah dalam Klaster 1 memiliki tingkat kemiskinan yang rendah serta didukung oleh akses infrastruktur dasar yang memadai.

Klaster 2 memiliki karakteristik yang sangat mirip dengan Klaster 1 dan dapat dikategorikan sebagai kelompok wilayah dengan kondisi sosial ekonomi terbaik. Klaster ini memiliki persentase penduduk miskin sebesar 10,447% dan nilai P2 sebesar 0,372 yang merupakan nilai terendah di antara seluruh klaster. Tingkat pendidikan juga relatif tinggi dengan persentase tamat SD/SMP sebesar 54,166%. Akses terhadap air layak dan sanitasi layak masing-masing mencapai 84,844% dan 86,462%. Dengan tingkat kemiskinan yang rendah, keparahan kemiskinan yang sangat kecil, serta kualitas fasilitas dasar yang baik, Klaster 2 mencerminkan wilayah dengan kondisi kesejahteraan yang relatif lebih baik dibandingkan klaster lainnya.

Klaster 3 merupakan kelompok wilayah dengan tingkat kemiskinan paling tinggi. Persentase penduduk miskin mencapai 42,560% dan nilai P2 sebesar 4,955, yang merupakan nilai tertinggi di antara seluruh klaster. Selain itu, persentase penduduk yang tidak bekerja juga sangat tinggi, yaitu 67,890%, menunjukkan keterbatasan kesempatan kerja pada wilayah dalam klaster ini. Meskipun demikian, akses sanitasi layak masih tergolong baik sebesar 88,150%. Tingginya tingkat kemiskinan, keparahan kemiskinan, dan pengangguran menunjukkan bahwa Klaster 3 merupakan kelompok wilayah yang menghadapi permasalahan ekonomi paling serius dibandingkan klaster lainnya.

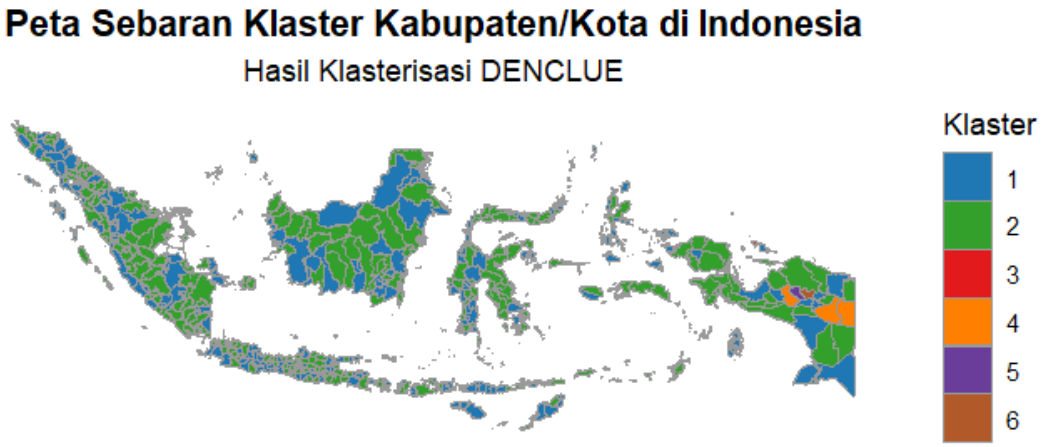
Klaster 4 menunjukkan karakteristik yang berbeda, persentase penduduk miskin tergolong tinggi yaitu 31,140%, namun nilai P2 hanya sebesar 0,631 sehingga tingkat keparahan kemiskinan relatif rendah. Persentase penduduk yang tidak bekerja juga merupakan yang terendah, yaitu 12,070%, sementara persentase pekerja sektor informal mencapai 87,186%, tertinggi di antara seluruh klaster. Di sisi lain, akses air layak dan sanitasi layak sangat rendah, masing-masing hanya sebesar 42,960% dan 13,903%. Kondisi ini menunjukkan bahwa sebagian besar penduduk bekerja, tetapi didominasi oleh pekerjaan sektor informal dan masih menghadapi keterbatasan akses terhadap fasilitas dasar.

Klaster 5 memiliki tingkat kemiskinan yang cukup tinggi dengan persentase penduduk miskin sebesar 35,460% dan nilai P2 sebesar 2,955. Sebagian besar penduduk bekerja di sektor informal dengan persentase sebesar 76,410%, sedangkan tingkat pengangguran relatif rendah yaitu 23,590%. Karakteristik yang menonjol dari klaster ini adalah akses air layak yang sangat tinggi mencapai 92,980%, tertinggi di antara seluruh klaster. Namun demikian, akses sanitasi layak masih rendah yaitu 25,010%. Oleh karena itu, Klaster 5 dapat digambarkan sebagai kelompok wilayah dengan tingkat kemiskinan yang masih cukup tinggi, tetapi telah memiliki akses air layak yang sangat baik.

Klaster 6 merupakan kelompok wilayah dengan tingkat pendidikan terendah, ditunjukkan oleh persentase tamat SD/SMP yang hanya sebesar 13,010%. Selain itu, persentase pengeluaran untuk makanan mencapai 78,200%, tertinggi di antara seluruh klaster, yang menunjukkan bahwa sebagian besar pengeluaran rumah tangga masih digunakan untuk memenuhi kebutuhan dasar. Persentase penduduk miskin juga relatif tinggi sebesar 28,750%, dengan dominasi pekerja sektor informal sebesar 81,330%. Akses air layak dan sanitasi layak merupakan yang terendah dibandingkan klaster lainnya, masing-

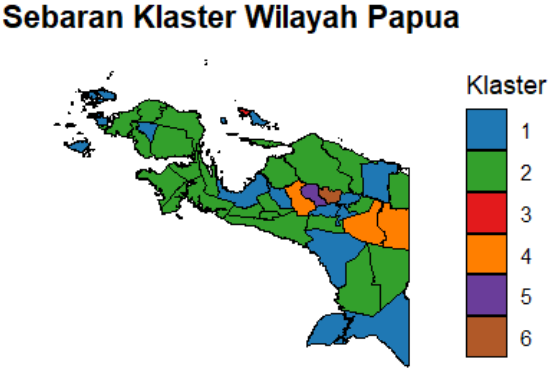
masing sebesar 30,120% dan 10,560%. Karakteristik tersebut menunjukkan bahwa Klaster 6 merupakan kelompok wilayah yang menghadapi kerentanan multidimensi, baik dari aspek pendidikan, kondisi ekonomi, maupun akses terhadap fasilitas dasar.

Secara umum, hasil clustering menunjukkan bahwa Klaster 1 dan Klaster 2 merupakan kelompok wilayah dengan kondisi sosial ekonomi relatif baik. Klaster 3 merupakan kelompok wilayah dengan tingkat kemiskinan dan keparahan kemiskinan tertinggi. Sementara itu, Klaster 4, Klaster 5, dan Klaster 6 memiliki karakteristik kerentanan yang berbeda-beda, yaitu dominasi sektor informal dan rendahnya akses fasilitas dasar pada Klaster 4, kemiskinan yang masih tinggi meskipun memiliki akses air layak yang baik pada Klaster 5, serta kerentanan multidimensi pada Klaster 6 yang ditandai oleh rendahnya tingkat pendidikan dan rendahnya akses terhadap fasilitas dasar.



Gambar 2. Peta Sebaran Klaster

Secara umum, pola yang terbentuk pada peta sebaran nasional menunjukkan dominasi mutlak dari Klaster 1 yang berwarna biru dan Klaster 2 yang berwarna hijau di hampir seluruh kepulauan utama, mulai dari Sumatra, Jawa, Bali, Nusa Tenggara, Kalimantan, hingga Sulawesi. Hal ini mengindikasikan adanya homogenitas struktur kesejahteraan dan pemenuhan infrastruktur dasar yang cukup merata di tingkat nasional, di mana sebagian besar wilayah di luar Pulau Papua telah berhasil mencapai batas minimum pelayanan fasilitas dasar dengan akses air bersih dan sanitasi layak di atas 84% serta mampu menekan angka kemiskinan di kisaran 10%. Temuan paling menarik dari hasil *clustering* spasial ini adalah munculnya pola yang memperlihatkan sebuah klaster geografis yang sangat kontras di bagian timur Indonesia.



Gambar 3. Peta Sebaran Klaster di Papua

Wilayah-wilayah yang terletak di sepanjang pesisir pantai dan kawasan Kepala Burung, seperti Sorong, Merauke, dan wilayah sekitar Jayapura, terbukti masih mampu bergabung ke dalam jaringan nasional Klaster 1 dan Klaster 2. Kondisi ini menandakan bahwa kedekatan geografis dengan jalur perdagangan laut dan aksesibilitas yang terbuka berkorelasi positif terhadap tingkat kesejahteraan masyarakat serta pemenuhan infrastruktur dasar yang setara dengan wilayah luar Papua. Sebaliknya, begitu pergeseran wilayah bergerak masuk ke arah pedalaman dan kawasan pegunungan tengah, warna peta langsung berubah drastis didominasi oleh Klaster 4 yang berwarna oranye. Secara keseluruhan, analisis sebaran spasial menggunakan pendekatan algoritma berbasis densitas ini membuktikan bahwa permasalahan kemiskinan, keterbatasan pendidikan, dan ketimpangan infrastruktur di Indonesia bukan lagi sekadar masalah antar-kabupaten yang bersifat acak. Temuan ini menegaskan bahwa pemerintah tidak dapat lagi menggunakan kebijakan generalisasi berskala nasional yang seragam, melainkan harus merancang pendekatan berbasis karakteristik lokal untuk mengintervensi klaster-klaster rentan yang berada di pedalaman Papua tersebut.

5. KESIMPULAN

Jumlah klaster optimal pada algoritma *density-base clustering* (DENCLUE) kernel Gaussian berdasarkan indikator kemiskinan yaitu sebanyak 6 klaster. Hasil pengelompokan kabupaten/kota berdasarkan indikator kemiskinan di Indonesia menggunakan algoritma *density-base clustering* (DENCLUE) dengan evaluasi klaster *Density-Based Clustering Validation* (DBCV) sebesar 0,8152. Jumlah klaster terbaik pada kabupaten/kota di Indonesia berdasarkan indikator kemiskinan menggunakan algoritma *density-base clustering* (DENCLUE) kernel Gaussian dan evaluasi klaster *Density-Based Clustering Validation* (DBCV), yaitu sebanyak 6 klaster dengan klaster 1 beranggotakan 223 kabupaten/kota, klaster 2 beranggotakan 285 kabupaten/kota, klaster 3 beranggotakan 1 kabupaten/kota, klaster 4 beranggotakan 3 kabupaten/kota, klaster 5 beranggotakan 1 kabupaten/kota, dan klaster 6 beranggotakan 1 kabupaten/kota

DAFTAR PUSTAKA

Ajmal, O., Arshad, H., Arshed, M. A., Ahmed, S., & Mumtaz, S. (2024). Robust Parameter Optimisation of *Noise*-Tolerant Clustering for DENCLUE Using Differential Evolution. *Mathematics*, *12*(21). https://doi.org/10.3390/math12213367

Anton, H., & Kaul, A. (2019). *Applications and Historical Topics *Section in the Applications Version **Web Module*.

Chicco, D., Sabino, G., Oneto, L., & Jurman, G. (2025). The DBCV index is more informative than DCSI, CDbw, and VIASCKDE indices for unsupervised clustering internal assessment of concave-shaped and density-based clusters. *PeerJ Computer Science*, *11*. https://doi.org/10.7717/peerj-cs.3095

Davis, R. A., Lii, K.-S., & Politis, D. N. (2011). Remarks on Some Nonparametric Estimates of a Density Function. *Selected Works of Murray Rosenblatt*, 95–100. https://doi.org/10.1007/978-1-4419-8339-8_13

Hinneburg, A., & Keim, D. A. (1998). *An Efficient Approach to Clustering in Large Multimedia Databases with Noise*. www.aaai.org

Moulavi, D., Jaskowiak, P. A., Campello, R. J. G. B., Zimek, A., & Sander, J. (2014). Density-based clustering validation. *SIAM International Conference on Data Mining 2014, SDM 2014*, *2*(i), 839–847. https://doi.org/10.1137/1.9781611973440.96

Todaro, M. P., & Smith, S. C. (2020). Economic Development (13th ed.). In *Pearson*. http://eco.eco.basu.ac.ir/BasuContentFiles/57/57304a77-1269-4081-bd5b-4c66b84b06a4.pdf

Xu, R., & Wunsch, D. (2005). Survey of clustering algorithms. *IEEE Transactions on Neural Networks*, *16*(3), 645–678. https://doi.org/10.1109/TNN.2005.845141